

Predicción del consumo de energía de electrodomésticos

Rutinas temporales y condiciones climáticas interiores y exteriores

Presentación para el Modelatón

Equipo 7

Universidad Autónoma de Nuevo León

27 de julio de 2026

Jorge Castillo Acosta

Jorge Ochoa Ruelas

Ulises Jared Escobar Gonzalez (2040270)

Giselle Arredondo Cepeda (2189558)

Miguel Cabrera Quiroz (117666)

Aldo Gabriel Gómez Canizales

jorge.castillocs@uanl.edu.mx

jorge.ochoaru@uanl.edu.mx

ulises.escobarg@uanl.edu.mx

giselle.arredondoc@uanl.edu.mx

miguel.cabreraq@uanl.edu.mx

aldo.gomezc@uanl.edu.mx

Objetivo del proyecto

Pregunta de investigación

¿En qué medida pueden predecirse los consumos de los electrodomésticos a partir de las rutinas horarias y de las condiciones ambientales de una vivienda?

Hipótesis de trabajo

- El gasto eléctrico no es completamente aleatorio.
- Las actividades domésticas generan patrones por hora y día.
- La temperatura y la humedad modifican esos patrones.

Objetivo analítico

- Comparar tres familias de regresión.
- Evaluar su capacidad de generalización temporal.
- Traducir los resultados en acciones de ahorro energético.

Appliances Energy Prediction


Dataset del *UCI Machine Learning Repository* con **19,735 observaciones** registradas cada 10 minutos durante aproximadamente 4.5 meses de 2016.

- Objetivo: Appliances, consumo en Wh.
- Temperatura y humedad en distintas habitaciones.
- Variables meteorológicas exteriores.
- Uso de luces y marca temporal.

Implementación en Python

- pandas
- numpy<2
- matplotlib
- seaborn
- scikit-learn

Semilla fija `random_state=42` para garantizar reproducibilidad.



Control de fuga de información

- Se excluyeron $rv1$ y $rv2$ por ser ruido.
- El escalador lineal se ajustó únicamente con entrenamiento.
- El conjunto de prueba representa observaciones futuras.

Variables temporales creadas

- Hora del día: $0, \dots, 23$.
- Día de la semana: $0, \dots, 6$.
- Indicador de fin de semana.

Competencia de modelos

Regresión Lineal

Relación continua y aditiva. Es interpretable y puede extrapolar su tendencia fuera del rango observado.

Random Forest

Promedia múltiples árboles. Captura interacciones no lineales y reduce la varianza, pero predice mediante regiones aprendidas.


Gradient Boosting

Construye árboles secuenciales que corrigen errores. Es flexible, aunque conserva la limitación de extrapolación de los árboles.

Criterio de comparación

El mejor modelo no es solamente el que ajusta relaciones complejas: debe generalizar cuando el clima del periodo futuro difiere del clima usado para entrenar.

Punto crítico: el corte cronológico cambia la estación



- La temperatura exterior media aumenta de aproximadamente 5.9°C a 13.6°C .
- La humedad exterior media disminuye de aproximadamente 81.8% a 71.4% .
- El consumo medio permanece cercano a 98 Wh en entrenamiento y 96 Wh en prueba.

Hallazgo

El cambio ocurre principalmente en las **variables predictoras**, no en la media del consumo objetivo.

La prueba contiene temperaturas de primavera que los modelos no observaron durante el entrenamiento invernal.

¿Por qué fallan los modelos basados en árboles?

Regresión lineal: función continua

$$\hat{y} = \beta_0 + \sum_{j=1}^p \beta_j x_j$$

Si una temperatura supera el rango de entrenamiento, la ecuación puede prolongar la tendencia estimada, aunque la extrapolación también implica riesgo.

Árboles: función constante por regiones

$$\hat{y} = \sum_{m=1}^M c_m \mathbb{I}(\mathbf{x} \in R_m)$$

Una observación fuera del rango conocido termina en alguna hoja extrema; el árbol no construye una pendiente más allá de su última partición.

Consecuencia empírica

Random Forest y Gradient Boosting asociaron las temperaturas nuevas con hojas cálidas de entrenamiento que coincidían con alta actividad. Esto produjo una **sobreestimación sistemática** y valores de R^2 negativos.

Resultados con separación cronológica 80/20

Modelo	Predicción media	R^2 aproximado
Regresión Lineal	≈ 96 Wh	0.09
Random Forest	≈ 276 Wh	-4.8
Gradient Boosting	≈ 280 Wh	-5.8

Interpretación de $R^2 < 0$

El modelo tiene mayor error cuadrático que una referencia ingenua que siempre predice la media del conjunto de prueba.

Resultado principal

La flexibilidad no lineal no compensó la incapacidad de extrapolar hacia un régimen térmico no observado.

Validación: ¿es un defecto del modelo o del escenario?

Modelo	R^2 aproximado	
	Cronológico	Aleatorio
Regresión Lineal	0.09	0.15
Random Forest	-4.8	0.54
Gradient Boosting	-5.8	0.45

Prueba de contraste

Con un split aleatorio 80/20, entrenamiento y prueba comparten estaciones y rangos ambientales semejantes.

- Los árboles recuperan su eficacia.
- Random Forest obtiene el mejor ajuste.
- Se confirma que el fallo era de **extrapolación estacional**.

Implicación metodológica

El split aleatorio mide interpolación dentro del periodo observado; el split cronológico representa mejor el riesgo real de predecir el futuro.

Variables más determinantes

1. Hora del día

Resume rutinas de ocupación, cocina, limpieza y descanso. Es la señal temporal más directamente vinculada con la demanda doméstica.

2. Uso de luces

lights funciona como indicador de presencia y actividad, además de representar consumo eléctrico directo.

3. Temperaturas interiores

Destacan T_3 (lavandería) y T_2 (sala), asociadas con actividad doméstica y condiciones térmicas de la vivienda.

Lectura causal prudente

La importancia predictiva no demuestra causalidad. Estas variables permiten anticipar el consumo, pero pueden actuar como indicadores de ocupación o rutina.

Recomendaciones de ahorro energético

1. Desplazar cargas pesadas a horas valle.

Programar lavadora, secadora y otros equipos de alta potencia fuera de los periodos de mayor actividad, siempre que la tarifa y la operación lo permitan.

2. Automatizar inteligentemente la iluminación.

Usar sensores de presencia, temporizadores y reglas por horario para evitar luces encendidas sin ocupación.

3. Incorporar control térmico contextual.

Ajustar ventilación y climatización según temperatura interior, exterior y ocupación, en lugar de emplear umbrales fijos aislados.

4. Reentrenar y vigilar el modelo por estación.

Actualizar los árboles con datos recientes y monitorear cambios en rangos de temperatura, error y distribución de variables.

Conclusiones

- El consumo presenta estructura asociada con **rutinas horarias**, iluminación y clima interior/exterior.
- Random Forest y Gradient Boosting son competitivos cuando prueba y entrenamiento comparten el mismo régimen ambiental.
- Con validación cronológica, el paso de invierno a primavera expone su incapacidad matemática para extrapolar y genera R^2 marcadamente negativos.
- La Regresión Lineal fue más robusta ante el cambio de estación, aunque su poder explicativo fue moderado.
- En producción se requiere validación temporal, monitoreo de deriva, reentrenamiento periódico y, en su caso, modelos explícitamente estacionales.

Mensaje final

La elección del modelo depende del horizonte operativo: **interpolan en condiciones conocidas** no equivale a **predecir una estación nueva**.

Gracias

Preguntas y discusión

Equipo 7 — Modelatón 2026